

Ejercicios de Bono

Debbie Echanique, Geoconda Molina, Fabián Encarnación

2024-02-29

Ejercicio 1

Sea $\{X_1, \dots, X_n\}$ una **m.a.s.** de X con distribución F . verificando que $\mathbb{E}[X]^6 < \infty$. Considere la estimación de $\eta = \mu^3$ con $\mu = \mathbb{E}[X]$:

1. Crear el U-estadístico para estimar ηU_n

Mediante $h(x_1, x_2, x_3) = x_1 x_2 x_3$ podemos obtener el U-estadístico para $\eta = \mu^3$

$$\begin{aligned} U_n &= \binom{n}{3}^{-1} \sum_{1 \leq i < j < k \leq n} h(X_i, X_j, X_k) \\ &= \frac{6}{n(n-1)(n-2)} \sum_{1 \leq i < j < k \leq n} X_i X_j X_k \end{aligned}$$

donde $\sum_{1 \leq i < j < k \leq n}$ es la suma de $\binom{n}{3}$ combinaciones de $\{i, j, k\}$ en $\{1, \dots, n\}$

2. Calcular el U-estadístico proyectado

Dado que $\eta = \mathbb{E}[h(X_1, X_2, X_3)]$ la proyección de U_n es:

$$\hat{U}_n = \frac{3}{n} \sum_{i=1}^3 h_1(X_i) + \eta$$

donde $h_1(x) = \mathbb{E}[h(x, X_2, X_3)] - \eta$.

Si tomamos $X_1 = x$, entonces:

$$\begin{aligned} \mathbb{E}[h(X_1, X_2, X_3)|X_1 = x] &= \mathbb{E}[h(x, X_2, X_3)] \\ &= \mathbb{E}[x X_2 X_3] \\ &= x \mathbb{E}[X_2 X_3] \\ &= x \mu^2 \end{aligned}$$

Luego,

$$\hat{U}_n = \frac{3}{n} [\mu^2 \sum_{i=1}^3 X_i + (\frac{n}{3} - 3)\eta]$$

$$= \frac{3}{n} \sum_{i=1}^3 \{\mathbb{E}[h(X_1, X_2, X_3)|X_i] - \eta\} + \eta$$

$$= \frac{3}{n} \sum_{i=1}^3 \{\mathbb{X}_i \mu^2 - \eta\} + \eta$$

3. Calcular la varianza de U_n

Tenemos que:

$$\text{Var}(U_n) = \binom{n}{3}^{-1} \sum_{k=1}^3 \binom{3}{k} \binom{n-3}{3-k} \xi_k$$

con $\xi_k = \text{Var}(h_k(X_1, \dots, X_n))$. Y por tanto:

$$\begin{aligned} \text{Var}(U_n) &= \binom{n}{3}^{-1} \sum_{k=1}^3 \binom{3}{k} \binom{n-3}{3-k} (h_k(X_1, \dots, X_n)) \\ &= \binom{n}{3}^{-1} \frac{3}{2} (n-4)(n-5) \text{Var}(h_1(X_1)) + 3(n-3) \text{Var}(h_2(X_1, X_2)) + \text{Var}(h_3(X_1, X_2, X_3)) \\ &= \binom{n}{3}^{-1} \frac{3}{2} (n-4)(n-5) \text{Var}(X_1) + 3(n-3) \text{Var}(X_1 X_2) + \text{Var}(X_1 X_2 X_3) \end{aligned}$$

4. Calcular $\frac{\mathbb{E}[\bar{X}^3]}{\mathbb{E}[U_n]} = C_n$ y qué sucede cuando $\lim_{n \rightarrow \infty}$

Tenemos que:

$$\begin{aligned} \frac{\mathbb{E}[\bar{X}^3]}{\mathbb{E}[U_n]} &= \frac{\frac{1}{n^3} \sum_i \mathbb{E}X_i^3 + 3 \sum_{i \neq j} \mathbb{E}X_i X_j^2 + \sum_{i \neq j \neq k} \mathbb{E}X_i X_j X_k}{\frac{6}{n(n-1)(n-2)} \sum_{1 \leq i < j < k \leq n} X_i X_j X_k} \\ &= \frac{n \mathbb{E}X^3 + 3 \binom{n}{2} \mu \mathbb{E}X^2 + \binom{n}{3} \mu^3}{n^3 \mu^3} \\ &= C_n \end{aligned}$$

Para $n \rightarrow \infty$,

$$\begin{aligned} C_n &= \frac{\mathbb{E}X^3}{n^2 \mu^3} + \frac{3(n-1)\mathbb{E}X^2}{2n^2 \mu^3} + \frac{(n-1)(n-2)}{6n^2} \\ C_n &\rightarrow \frac{1}{6} \end{aligned}$$

Ejercicio 2

A continuación deduciremos la probabilidad de que una observación determinada forme parte de una muestra bootstrap. Supongamos que obtenemos una muestra bootstrap a partir de un conjunto de n observaciones.

a. ¿Cuál es la probabilidad de que la primera observación bootstrap no sea la j -ésima observación de la muestra original?. Justifique su respuesta.

Esto es 1-probabilidad de que sea la j -ésima. Es decir:

$$P = 1 - \frac{1}{n}$$

b. ¿Cuál es la probabilidad de que la segunda observación bootstrap no sea la j ésima observación de la muestra original?

Como cada observación bootstrap es una muestra aleatoria, la probabilidad es la misma:

$$P = 1 - \frac{1}{n}$$

c. Argumentar que la probabilidad de que la observación j ésima no esté en la muestra bootstrap es $(1 - 1/n)^n$

Para que la observación j ésima no esté en la muestra, tendría que no estar en cada posición n , en otras palabras, no ser elegida en $1, 2, \dots, n$. Por lo tanto la probabilidad es:

$$P = \left(1 - \frac{1}{n}\right)^n$$

d. Cuando $n = 5$, ¿cuál es la probabilidad de que la j ésima observación esté en la muestra bootstrap?

Utilizando la respuesta del literal anterior, se tiene:

```
n<-5
p<-1-(1-1/n)^n
cat("La probabilidad es:", p)
```

```
## La probabilidad es: 0.67232
```

e. Cuando $n = 100$, ¿cuál es la probabilidad de que j ésima observación esté en la muestra bootstrap?

Análogo al literal anterior:

```
n<-100
p<-1-(1-1/n)^n
cat("La probabilidad es:", p)
```

```
## La probabilidad es: 0.6339677
```

e. Cuando $n = 10000$, ¿cuál es la probabilidad de que j ésima observación esté en la muestra bootstrap?

Análogo a los literales anteriores:

```
n<-100000
p<-1-(1-1/n)^n
cat("La probabilidad es:", p)
```

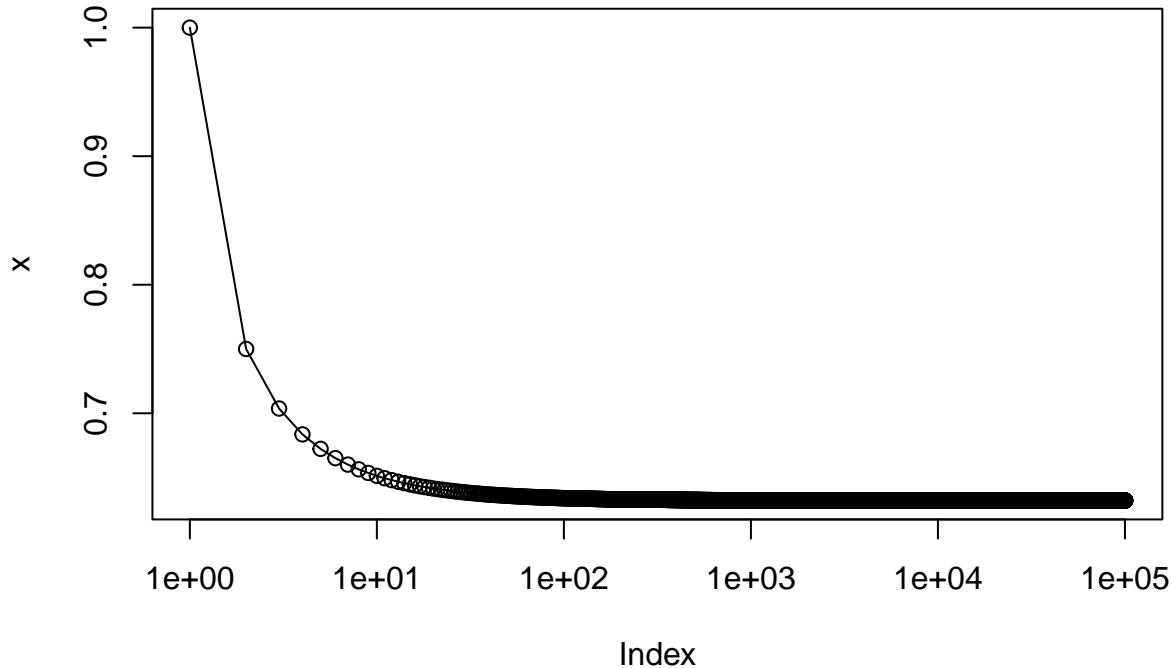
```
## La probabilidad es: 0.6321224
```

g. Crear un gráfico que muestre, para cada valor de n desde 1 a 100000, la probabilidad de que la j ésima observación esté en la muestra bootstrap. Comentar lo que se observa

```

x<-numeric(100000)
for (i in 1:100000) {
  x[i]<-1-(1-1/i)^i
}
plot(x,log="x",type="o")

```



La probabilidad se acerca a 0.63 cuando n va creciendo.

Dado que:

$$e^x = \lim_{n \rightarrow \infty} \left(1 + \frac{x}{n}\right)^n,$$

Tomando $x = -1$, se tiene que la probabilidad cuando n tiende a infinito es:

$$P = 1 - \frac{1}{e}$$

h. Ahora investigaremos numéricamente la probabilidad de que una muestra bootstrap de tamaño $n = 100$ contenga la j ésima observación. Aquí $j = 4$. Creamos repetidamente muestras bootstrap, y cada vez registramos si la cuarta observación está contenida o no en la muestra bootstrap.

```

store <- rep(NA, 10000)
for (i in 1:10000) {
  store[i] <- sum(sample(1:100, rep = TRUE) == 4) > 0
}
mean(store)

```

```
## [1] 0.6327
```

Vemos que la probabilidad cuando se remuestrea es cercana al límite encontrado en el literal anterior

Ejercicio 9

Seguimos considerando el uso de un modelo de regresión logística para predecir la probabilidad de `default` utilizando `income` y `balance` en el conjunto de datos `Default`. En concreto, ahora calcularemos las estimaciones de los errores estándar de los coeficientes de regresión logística de `income` y `balance` de dos formas diferentes: (1) utilizando el bootstrap, y (2) utilizando la fórmula estándar para calcular los errores estándar en la función `glm()`. No olvide establecer una semilla aleatoria antes de comenzar el análisis.

1. Utilizando las funciones `summary()` y `glm()`, determine los errores estándar estimados para los coeficientes asociados con `income` y `balance` en un modelo de regresión logística múltiple que utiliza ambos predictores.

```
data(Default)
fit <- glm(default ~ income + balance, data = Default, family = "binomial")
summary(fit)
```

```
##
## Call:
## glm(formula = default ~ income + balance, family = "binomial",
##      data = Default)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.154e+01  4.348e-01 -26.545 < 2e-16 ***
## income       2.081e-05  4.985e-06   4.174 2.99e-05 ***
## balance      5.647e-03  2.274e-04  24.836 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 2920.6  on 9999  degrees of freedom
## Residual deviance: 1579.0  on 9997  degrees of freedom
## AIC: 1585
##
## Number of Fisher Scoring iterations: 8
```

Los errores estándar obtenidos por el método bootstrap son: $\beta_1 = 5e^{-6}$ and $\beta_2 = 2.3e^{-4}$.

2. Escriba una función, `boot.fn()`, que tome como entrada el conjunto de datos `Default` así como un índice de las observaciones, y que produzca las estimaciones de los coeficientes para `income` y `balance` en el modelo de regresión logística múltiple.

```
boot.fn <- function(x, i) {
  fit <- glm(default ~ income + balance, data = x[i, ], family = "binomial")
  coef(fit)[-1]
}
```

3. Utilice la función `boot()` junto con su función `boot.fn()` para estimar los errores estándar de los coeficientes de regresión logística para los ingresos y el saldo.

```
library(boot)
set.seed(42)
boot(Default, boot.fn, R = 1000)

##
## ORDINARY NONPARAMETRIC BOOTSTRAP
##
##
## Call:
## boot(data = Default, statistic = boot.fn, R = 1000)
##
##
## Bootstrap Statistics :
##      original     bias   std. error
## t1* 2.080898e-05 2.737444e-08 5.073444e-06
## t2* 5.647103e-03 1.176249e-05 2.299133e-04
```

4. Comente los errores estándar estimados obtenidos utilizando la función `glm()` y utilizando su función `bootstrap`.

Podemos notar que los errores estandar obtenidos por el método bootstrap son iguales a los obtenidos por `glm()`

```
\end{document}
```